Activation Service

Manual do Desenvolvedor: visão técnica do projeto para quem vai avaliá-lo ou mantê-lo

Este documento resume o que foi construído, onde cada item do desafio está atendido e por que as principais decisões foram tomadas. O detalhamento completo está no repositório: `README.md`, `docs/spec` (requisitos, design e plano) e `docs/adr` (quatro registros de decisão).

Java 21
Spring Boot 3.5

162
testes automatizados

100%
linhas e ramos (gate no build)

4
ADRs

SDD
especificação aprovada antes do código

Sumário

1. Visão geral
2. Como avaliar em 5 minutos
3. Mapa do desafio para a solução
4. Arquitetura
5. Ciclo de vida de uma solicitação
6. Decisões técnicas e trade-offs
7. Estratégia de testes
8. Operação e produção
9. Limitações conhecidas e próximos passos
10. Guia de leitura do código
11. Processo de desenvolvimento e uso de IA

1. Visão geral

API REST que recebe pedidos de ativação de produto, consulta o status e realiza a ativação num provedor externo. A solução se apoia em três decisões centrais:

- **Duplicidade garantida pelo banco:** uma constraint única em `external_id` decide qualquer corrida; o retry do sistema de origem recebe `200` com o registro existente, e conflitos recebem `409`.
- **Integração assíncrona e resiliente:** o `POST` grava `PENDING` e responde na hora; um worker usa a própria tabela como fila (`FOR UPDATE SKIP LOCKED`), chama o provedor fora de transação e trata cada resposta, com backoff exponencial, jitter, `Retry-After`, chave de idempotência e reconciliação de trabalho abandonado.
- **Segurança implementada:** OAuth 2.0 client credentials com JWT validado (assinatura, emissor, audiência, expiração), escopos de leitura e escrita e isolamento entre sistemas consumidores.

Camada	Tecnologia
Linguagem e framework	Java 21 (records, sealed interfaces, pattern matching) · Spring Boot 3.5 (Spring MVC, Spring Data JPA/Hibernate, Spring Security)
Persistência	PostgreSQL 16 · Flyway
Integração	`RestClient` sobre o `HttpClient` do JDK, com timeouts explícitos
Testes	JUnit 5 · Mockito · AssertJ · MockMvc · Testcontainers · WireMock · Awaitility · ArchUnit · JaCoCo
Operação	Actuator · Micrometer/Prometheus · logs JSON (ECS) · Docker multi-stage · Docker Compose · GitHub Actions
Documentação da API	OpenAPI (springdoc) · Swagger UI com login OAuth2 · coleção Postman

2. Como avaliar em 5 minutos

Pré-requisitos: JDK 21 e Docker em execução.

1. **Build e testes** (unitários, integração com PostgreSQL real, arquitetura e cobertura):

   ```
   ./mvnw verify
   ```

2. **Ambiente completo** (aplicação, PostgreSQL, provedor simulado e servidor OAuth2):

   ```
   docker compose up -d --build
   ```

3. **Explorar a API** em `http://localhost:18080/swagger-ui.html`: **Authorize** (credenciais de demonstração pré-preenchidas) → **select all** → **Authorize**, e então **Try it out** em qualquer operação.
4. **Ou rodar a coleção Postman** `docs/postman/activation-service.postman_collection.json`: 16 requisições com o resultado esperado verificado automaticamente.

Para observar os cenários de falha, o provedor simulado responde conforme o `productCode`: `INVALID-PRODUCT` (recusa 400), `UNAVAILABLE-PRODUCT` (503 com `Retry-After`), `SLOW-PRODUCT` (acima do timeout). As portas ficam na faixa 18xxx por padrão e podem ser trocadas por variável de ambiente (ver README).

3. Mapa do desafio para a solução

Cada item do enunciado, como foi atendido e onde verificar. `Impl.` = implementado e testado · `Desc.` = descrito no README.

Item do desafio		Como foi atendido	Onde verificar
1. Tecnologias	Impl.	Java 21, Spring Boot 3.5, Maven Wrapper, PostgreSQL, Flyway, Compose, CI; records e sealed + switch	`pom.xml`, `db/migration`, `.github/workflows`
2. POST e GET	Impl.	Validação, `201` + `Location`, datas UTC ISO-8601, DTOs separados da entidade, `404`	`ActivationRequestController` · `ActivationRequestControllerTest`, `ActivationRequestApiIT`
2. Listagem paginada	Impl.	Filtros por status e cliente, paginação, índices justificados	`V1__...sql`, `design.md` §4 · `ActivationRequestListingIT`
3. Duplicidade	Impl.	Constraint única; 200 para retry, 409 para conflito, 409 genérico entre clientes; explicação de por que verificar antes não basta	ADR-0002 · `DuplicateRequestConcurrencyIT` (20 threads)
4. Estados e transições	Impl.	Transições só por métodos do domínio; falha temporária volta para `PENDING`; `@Version`	`ActivationRequest` · `ActivationRequestTest`
5. Integração	Impl.	Tabela de retorno (2xx, 400, 401/403, 500, timeout, 429/503); assíncrono; sem HTTP dentro de transação; envio garantido mesmo com queda; timeouts configuráveis; `Idempotency-Key`; backoff com jitter e limite; reconciliação	ADR-0001, ADR-0003 · `ActivationProcessingIT`, `ProviderClientTest`
5. Circuit breaker	Desc.	Avaliado e deixado de fora conscientemente: o backoff persistido já protege o provedor	README · Pontos pendentes
6. Tratamento de erros	Impl.	RFC 9457 em todos os erros, inclusive 401/403/405/413/415; `traceId`; nenhum detalhe interno exposto	`ApiExceptionHandler` · `ApiExceptionHandlerTest`
7. Segurança	Impl.	Resource Server, escopos distintos, 401/403 testados sem servidor real, isolamento contra BOLA, limite de corpo; rate limiting no gateway	ADR-0004 · `JwtValidationIT`, `ActivationRequestControllerTest`
8. Testes	Impl.	Todos os cenários mínimos e todos os diferenciais da tabela: concorrência, timeout, domínio, segurança, ArchUnit	Seção 7 deste manual
9. Qualidade	Impl.	Pacotes com regras verificadas; commits pequenos, cada um com a intenção e a tarefa do plano citadas (tarefa → requisito em `tasks.md`)	`ArchitectureTest` · `git log`
Observabilidade	Impl.	Liveness e readiness, `traceId` da requisição até o provedor, métricas	`application.yml` · `ScheduledProcessingIT`

		Prometheus, logs JSON; OpenTelemetry descrito	
10. Cenário de análise	Desc.	Investigação, métricas, hipótese de causa comum e validação da correção	README · Cenário de análise
11. Docker	Impl.	Multi-stage, imagem JRE enxuta, não-root, memória ajustada ao container, desligamento gracioso, health check, compose completo	`Dockerfile`, `docker-compose.yml`
Microsserviços e cloud	Desc.	Várias instâncias, segredos, eventos via outbox, pipeline de CI/CD	README · Microsserviços e cloud
Entrega	Impl.	README com todas as seções obrigatórias, ADRs e uso de IA	`README.md`, `docs/adr`

Além do pedido: Swagger UI com login OAuth2 real, coleção Postman com verificações automáticas, gate de 100% de cobertura no build e especificação rastreável em `docs/spec`.

4. Arquitetura

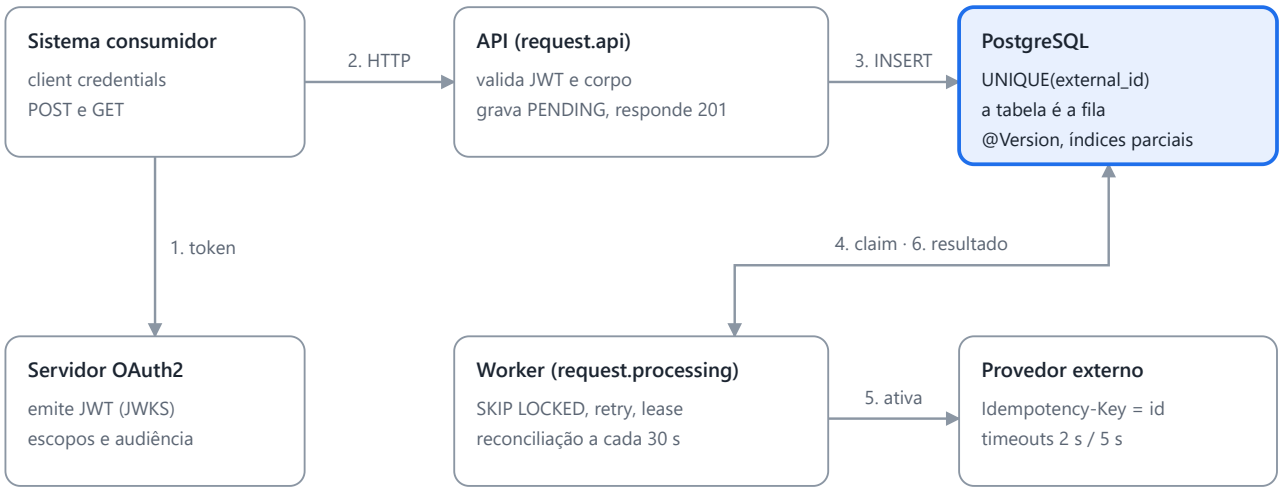


Figura 1 — componentes e quem fala com quem.

Organização dos pacotes

Um pacote por funcionalidade (`request`), com camadas leves dentro; código transversal em `shared`; o cliente do provedor isolado em `provider`.

Pacote	Responsabilidade	Regra (verificada pelo ArchUnit)
`request.domain`	Entidade, estados, regras de transição	Só depende do JDK e de `jakarta.persistence`
`request.api`	Controller, DTOs (records), contrato HTTP	Nunca acessa repositórios
`request.application`	Casos de uso: criar (duplicidade), consultar, listar	—
`request.persistence`	Repositório, queries de fila, specifications	—
`request.processing`	Worker, retry, reconciliação, métricas	—
`provider`	HTTP com o provedor, classificação das respostas	Não conhece nada de `request`
`shared`	Erros, segurança, correlação, filtros, OpenAPI, relógio	Não depende de nenhuma feature

Por que não hexagonal? O enunciado pede explicitamente para não exagerar. Pacote por funcionalidade dá coesão (tudo de "solicitação" junto) e as regras do ArchUnit garantem o essencial da arquitetura limpa — domínio independente e dependências apontando para dentro — sem interfaces de porta para cada adaptador.

5. Ciclo de vida de uma solicitação

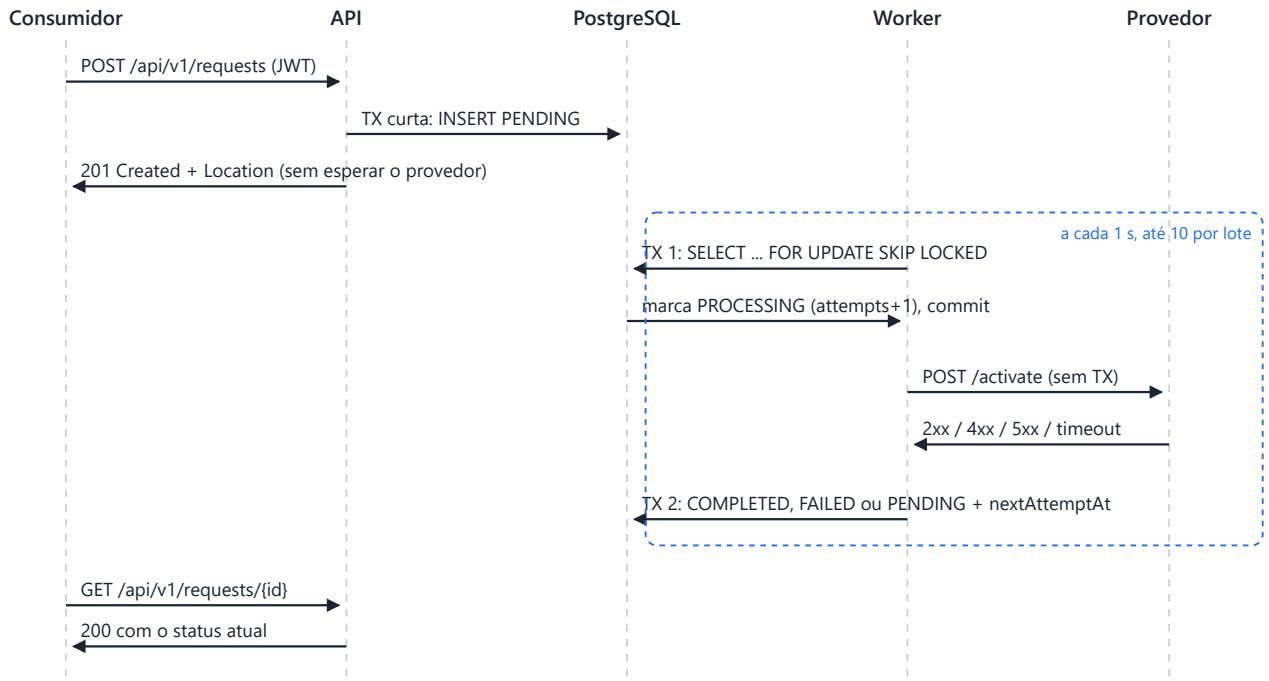


Figura 2 — sequência completa. Repare nas duas transações curtas com a chamada HTTP no meio, fora de qualquer transação.

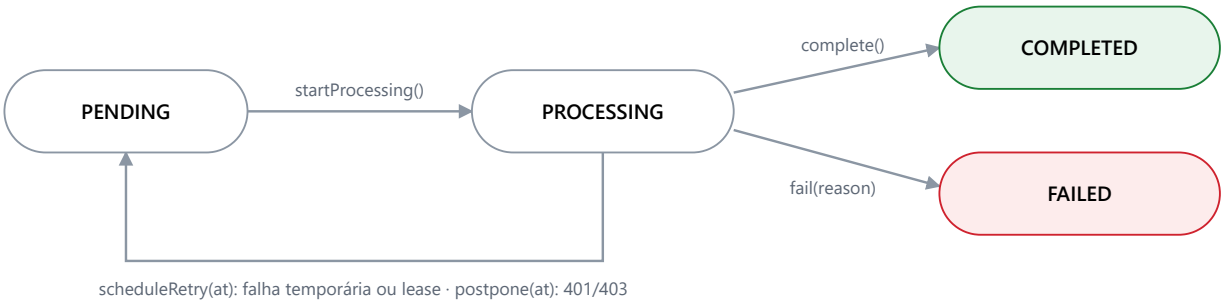


Figura 3 — máquina de estados. Só os métodos do domínio mudam o status; qualquer outra transição lança `IllegalStatusTransitionException`.

Invariantes que o sistema garante

- **Unicidade:** nunca existem dois registros com o mesmo `externalId` — garantido pelo banco, não pelo código.
- **Nada se perde:** um pedido aceito (201) está no banco; se a instância cair, outra o processa.
- **Nunca em paralelo:** duas instâncias não chamam o provedor ao mesmo tempo para o mesmo pedido (`SKIP LOCKED`).
- **Sem ativação dupla:** repetições ao provedor levam a mesma `Idempotency-Key`.
- **Estados finais são finais:** `COMPLETED` e `FAILED` não mudam mais.
- **Resultado atrasado não sobrescreve:** cada claim carrega o número da tentativa; resposta de uma tentativa antiga é descartada.

6. Decisões técnicas e trade-offs

As quatro decisões estruturais têm ADR em `docs/adr`, com contexto e consequências completos; abaixo, o resumo de cada uma e das decisões menores.

D1. Processamento assíncrono com a tabela como fila ADR-0001

Problema	O provedor pode ficar lento ou fora do ar; o pedido gravado não pode se perder se a aplicação cair entre o commit e a chamada.
Decisão	POST grava `PENDING` e responde; worker agendado reivindica lotes com `FOR UPDATE SKIP LOCKED`, chama o provedor fora de transação e grava o resultado.
Alternativas	Síncrono (latência acoplada ao provedor); `@Async` após o commit (evento em memória se perde); Kafka + outbox (infraestrutura extra sem ganho nesta escala).
Por que	Entrega *at-least-once* garantida pelo próprio banco, várias instâncias sem coordenação, nenhuma peça nova de infraestrutura.
Custo aceito	O cliente precisa consultar o status (polling); até 1 s de latência até a primeira tentativa; carga leve e constante de polling no banco.

D2. Duplicidade pela constraint única ADR-0002

Problema	O sistema de origem faz retry; duas requisições iguais podem chegar ao mesmo tempo, em instâncias diferentes.
Decisão	`UNIQUE(external_id)`; inserir direto e, na violação *dessa* constraint, reler fora da transação que falhou: mesmo conteúdo → 200; conteúdo diferente → 409; outro cliente → 409 genérico.
Alternativas	Verificar antes de inserir (falha em concorrência); `ON CONFLICT DO NOTHING` nativo (preso ao PostgreSQL); lock pessimista ou advisory lock (contenção desnecessária); 409 para toda repetição (ruim para quem faz retry).
Por que	Correto sob qualquer concorrência e número de instâncias; o caso comum custa um único INSERT.
Custo aceito	O método de criação não pode ser `@Transactional`; unicidade é global (não por cliente).

D3. Retry persistido, falha temporária volta para PENDING ADR-0003

Problema	Distinguir erro definitivo de temporário; o timeout é ambíguo (o provedor pode ter ativado).
Decisão	4xx → FAILED, exceto 401/403 (credencial nossa: adia 1 min sem gastar tentativa); 408, 5xx, timeout, I/O → PENDING com backoff exponencial e full jitter; 429/503 respeitam `Retry-After`; 5 tentativas no máximo; `Idempotency-Key` em toda chamada.
Alternativas	Retry em memória (Spring Retry/Resilience4j) prende a thread e se perde num restart; manter em PROCESSING com contador mistura "em andamento" com "aguardando".
Por que	O retry sobrevive a reinícios e se distribui entre instâncias; PROCESSING antigo vira sinal inequívoco de instância caída.
Custo aceito	Depende de o provedor honrar a chave de idempotência; FAILED por esgotamento exige ação operacional.

D4. OAuth2 Resource Server com isolamento por cliente ADR-0004

Problema	API consumida por sistemas; separar quem cria de quem consulta; impedir que um sistema leia dados de outro.
Decisão	Client credentials; JWT validado localmente (assinatura via JWKS, `iss`, `aud`, `exp`); escopos `activation:write` / `read`; dono = `client_id` do token, filtrado em toda consulta; outro dono → 404.
Alternativas	API key estática (sem expiração nem escopos); introspecção do token a cada chamada (latência extra); mTLS (complementar, não substitui autorização).
Custo aceito	Revogação só na expiração do token (mitigado por tokens curtos).

Outras decisões

Decisão	Justificativa curta
Spring Boot 3.5 (e não 4.x)	O enunciado pede 3.x, provável stack da empresa. O suporte OSS da 3.5 terminou em jun/2026; a migração está nas melhorias futuras.
PostgreSQL também nos testes	Unicidade concorrente, `SKIP LOCKED` e `TIMESTAMPTZ` se comportam diferente no H2 — passaria no teste e falharia em produção.
200 para retry, 409 para conflito	Retry é normal em integração; o cliente não deveria tratar erro como sucesso. O 200 (e não 201) indica que nada foi criado.
404 (não 403) para dado de outro cliente	403 confirmaria que o id existe (OWASP API1 — BOLA).
id malformado na URL → 404	Um identificador que não pode existir é um recurso inexistente; filtro inválido na query é 400.
`RestClient` sobre `HttpClient` do JDK	Síncrono, moderno, timeouts explícitos, sem trazer WebFlux; criado a partir do builder do Spring para ganhar métricas.
Relógio injetável com precisão de ms	Testes determinísticos; o PostgreSQL guarda microssegundos e arredondava nanos, fazendo o POST e o GET devolverem datas diferentes.
Mensagens de validação em inglês e explícitas	Sem isso, o Bean Validation responde no idioma da JVM — português numa máquina, inglês no container.
Actuator em porta separada	Health e métricas acessíveis ao orquestrador e ao Prometheus, nunca expostos publicamente.
`open-in-view: false`	Nenhuma conexão de banco presa enquanto a resposta é serializada.

7. Estratégia de testes

Nível	O que prova	Ferramentas / exemplos
Unitário puro	Regras sem infraestrutura: transições, retry, classificação de respostas, parsing	JUnit, AssertJ — `ActivationRequestTest`, `RetryPolicyTest`
Unitário com mocks	Decisões de orquestração: ramos da duplicidade, isolamento de erros no worker	Mockito — `ActivationRequestServiceTest`, `ActivationWorkerTest`
Slice web	Contrato HTTP, validação, formato de erro, 401/403/413	`@WebMvcTest`, MockMvc, `jwt()`
Integração	Comportamentos que dependem do banco e da rede real	Testcontainers (PostgreSQL), WireMock, Awaitility
Arquitetura	Regras de dependência e ausência de ciclos	ArchUnit

Testes que merecem atenção

- **Duplicidade concorrente:** 20 threads liberadas juntas por um `CountDownLatch`; 19 batem na constraint — a corrida é real.
- **Prova do SKIP LOCKED:** um worker segura 4 linhas numa transação aberta; o outro pega só as 2 restantes, sem esperar.
- **JWT real:** chaves RSA geradas no teste, JWKS publicado num WireMock, tokens expirados/forjados/de outra audiência recusados.
- **Resultado atrasado:** claim antigo tentando gravar depois de o pedido ter sido reprocessado — descartado.
- **Fluxo ponta a ponta:** agendador real ligado, Awaitility esperando o `COMPLETED`, verificação do header de correlação no provedor.

Cobertura de 100%

O build falha abaixo de 100% de linhas e ramos (JaCoCo, só o `main()` excluído). O objetivo não foi o número: ao fechar as lacunas, **código defensivo inatingível foi removido** em vez de testado artificialmente, e os testes novos **encontraram um bug real**. Num sistema grande, um gate um pouco menor somado à revisão de testes no code review seria mais saudável.

Defeitos encontrados durante o desenvolvimento

Bug	Como apareceu e como foi resolvido
POST e GET com datas diferentes	Revisão contra o enunciado; nanos em memória × micros no banco → relógio com precisão de ms + teste
`fail(null)` mudava o status antes de lançar	Teste novo de cobertura; validação movida para antes da mudança de estado
Header com caractere de controle virava 500	Teste de log injection; firewall do Spring Security → 400 em ProblemDetail
Ciclo de pacotes `shared ↔ request`	ArchUnit; exceções-base em `shared.error`
Teste instável com WireMock	Primeira chamada a um servidor frio estourava o timeout e gerava retry legítimo; timeouts de teste ajustados e asserções filtradas pela chave de idempotência

8. Operação e produção

Tema	Como está
Imagem Docker	Multi-stage, JRE Alpine, camadas do Spring Boot, usuário não-root, `MaxRAMPercentage=75`, `ExitOnOutOfMemoryError`, `exec` para receber SIGTERM, HEALTHCHECK
Ambiente local	`docker compose`: app, PostgreSQL, WireMock (provedor com cenários) e mock-oauth2-server
CI	GitHub Actions: `./mvnw verify` (testes, arquitetura, cobertura) + build da imagem
Configuração	Só variáveis de ambiente; segredos de um cofre (Key Vault / Secrets Manager)
Escala	Várias réplicas sem coordenação; worker pode ser separado da API com `activation.processing.enabled`
Desligamento	Gracioso: requisições em andamento terminam; o agendador espera até 30 s pela chamada em curso
Observabilidade	Probes, métricas Prometheus (provedor por resultado, transições, HTTP com histograma), logs JSON com `traceId`
Documentação viva	OpenAPI em `/v3/api-docs` e Swagger UI com login OAuth2 real

9. Limitações conhecidas e próximos passos

Pontos que ficaram de fora ou que merecem evolução, com o caminho proposto para cada um:

Limitação	Impacto	Como evoluir
Banco fora do ar → POST espera 30 s e responde 500	Cliente esperando à toa; 500 em vez de 503	`hikari.connection-timeout` curto e mapear falta de conexão para 503 + `Retry-After`
Unicidade de `externalId` global	Dois sistemas de origem não podem usar o mesmo id	`UNIQUE(client_id, external_id)`
Consumidor precisa fazer polling	Carga e latência de descoberta	Evento `ActivationCompleted` via outbox + Kafka, ou webhook
Sem circuit breaker	Com o provedor fora por muito tempo, tentativas são gastas	Resilience4j em volta do `ProviderClient`
Sem reprocessamento de `FAILED`	Operação manual no banco	Endpoint administrativo com escopo próprio e auditoria
Rate limiting	Não está na aplicação	No API Gateway, por `client_id`
Spring Boot 3.5 sem suporte OSS	Sem patches gratuitos	Migrar para 4.x (Jackson 3, Hibernate 7)
Tabela cresce sem limite	Volume e custo ao longo do tempo	Particionamento ou arquivamento por data
Credencial recusada (401/403) adia cada solicitação, sem pausa global	Uma chamada por solicitação por minuto enquanto a credencial não é corrigida	Circuit breaker pausando o worker inteiro; se o provedor usar 403 para recusa de negócio, devolver o 403 à regra de FAILED
`FAILED` após timeouts sucessivos	O provedor pode ter ativado; o status não reflete isso	Consultar o provedor pela `Idempotency-Key` antes de declarar falha, ou status `UNKNOWN`
Worker chama o provedor uma solicitação por vez	Cerca de 20 ativações/min por instância com o provedor a 3 s	Mais instâncias (`SKIP LOCKED`) ou paralelismo limitado dentro do lote
Paginação por offset com `count(*)`	Páginas profundas ficam caras	Paginação por cursor (`createdAt` , `id`)

10. Guia de leitura do código

Sugestão de ordem para percorrer o código; cada arquivo concentra uma ideia.

#	Arquivo	O que observar
1	`db/migration/V1__create_activation_request.sql`	Constraint única, `CHECK` de status, índices parciais para a fila e compostos para a listagem
2	`request/domain/ActivationRequest.java`	Sem setters; cada transição valida o estado; `@Version`; `fail` valida antes de mudar
3	`request/application/ActivationRequestService.java`	`create`: insere primeiro, decide na violação; por que **não** é `@Transactional`
4	`request/api/ActivationRequestController.java`	`switch` sobre o `sealed CreationResult`: 201 + Location ou 200
5	`request/persistence/ActivationRequestRepository.java`	Queries nativas com `FOR UPDATE SKIP LOCKED`
6	`request/processing/ActivationWorker.java`	Um erro não para o lote; MDC restaurado; timer por resultado
7	`request/processing/ActivationProcessingService.java`	As duas transações curtas; descarte de resultado atrasado; reconciliação
8	`provider/ProviderResponses.java` e `ProviderClient.java`	A tabela do item 5 em código; `sealed ProviderResult`; nunca lança exceção
9	`request/processing/RetryPolicy.java`	Backoff, jitter injetável, Retry-After, limite
10	`shared/security/SecurityConfiguration.java` e `CurrentClient.java`	Escopos por rota; fallback `client_id → azp → sub`
11	`shared/error/ApiExceptionHandler.java`	Todo erro em ProblemDetail, inclusive os do próprio Spring
12	`application.yml`	Cada propriedade tem um motivo; os comentários explicam

Recursos de Java moderno usados (e onde)

Recurso	Onde
`record`	DTOs, comandos, `ProviderResult`, propriedades
`sealed interface`	`CreationResult`, `ProviderResult`
Pattern matching no `switch`	Controller, processamento, métricas
Text blocks	Queries nativas, testes
`var`	Variáveis locais em todo o código
`@ConfigurationProperties` com record	`ProviderProperties`, `RetryProperties`

O ganho do `sealed` + `switch`: quando um novo tipo de `ProviderResult` é criado, o compilador aponta todo `switch` que não o trata. Foi o que aconteceu ao incluir `CredentialsRejected` (401/403): os dois `switch` que precisavam tratá-lo pararam de compilar até serem ajustados. É segurança em tempo de compilação para a regra de negócio mais sensível.

11. Processo de desenvolvimento e uso de IA

O projeto foi desenvolvido com o **Claude Code** (Anthropic) como ferramenta, dentro de um processo de **Spec-Driven Development**. A IA aumentou a velocidade de execução; o processo garantiu o controle sobre as decisões e a qualidade.

1. **Análise** do enunciado e da vaga: obrigatórios × diferenciais; o que implementar e o que descrever.
2. **Especificação antes do código** (`docs/spec`, `docs/adr`): requisitos com critérios de aceite, design e plano; alternativas comparadas para cada decisão estrutural e aprovadas antes da implementação.
3. **Implementação incremental** em cinco fases, com commits que citam a tarefa do plano (ligada aos requisitos em `tasks.md`) e um checkpoint de revisão ao fim de cada fase.
4. **Verificação** por testes automatizados (critério de pronto), execução real da stack e revisões contra o enunciado.

Responsabilidade	Desenvolvedor	IA (Claude Code)
Escopo e prioridades	Definiu	Propôs opções
Decisões técnicas e trade-offs	Escolheu e aprovou	Levantou alternativas, prós e contras
Especificação e ADRs	Revisou e aprovou	Redigiu a partir das decisões
Código, testes e infraestrutura	Revisou a cada checkpoint	Implementou, tarefa por tarefa
Critérios de qualidade	Definiu (cobertura total, plano de QA, revisão contra o enunciado)	Executou e reportou
Validação final	Testou manualmente a aplicação	Rodou builds, testes e verificações

As revisões encontraram defeitos que uma geração direta de código teria deixado passar (seção 7). O detalhamento está na seção **Uso de IA** do README.